



UNIVERSIDAD DE CARABOBO
FACULTAD DE INGENIERIA
MAESTRIA EN MATEMÁTICAS Y COMPUTACION

**Auditoría Estocástica de la Demanda Eléctrica en Sistemas
con Censura Telemétrica: Un Enfoque mediante
Teledetección y Calibración Fotométrica**

Autor: Ing. Melvin E. Padilla
Cátedra: Estadística Avanzada
Profesor: Ing. Eduardo Vargas

Valencia, Junio de 2026

Resumen

El presente trabajo de investigación documenta el desarrollo de un marco metodológico bidireccional que integra la modelación estocástica abstracta y la matemática aplicada para la resolución de problemas de datos censurados en sistemas de potencia. En la primera fase, se evalúa mediante simulaciones de Monte Carlo (5000 iteraciones) la sensibilidad empírica del Error Tipo I del Análisis de Varianza (ANOVA) bajo escenarios de heterocedasticidad y desbalance muestral, demostrando matemáticamente la vulnerabilidad de las pruebas clásicas ante la asimetría de varianzas regional. En la segunda fase, se diseña un algoritmo de intercalibración cruzada no lineal fundamentado en ratios de potencia fotométrica, utilizando series temporales multiespectrales de los sensores DMSP y NOAA-VIIRS. Al aislar los nodos socio-industriales y depurar los sesgos espaciales de combustión (*flaring*), la auditoría estocástica confirma una asimetría ($S_k = 0,505$) y heterocedasticidad extremas ($p = 3,90 \times 10^{-18}$). Finalmente, el modelo estima la demanda máxima servida del Sistema Eléctrico Nacional para el período 2021-2026 en $\hat{\mu} = 6315,42$ MW, con un intervalo de confianza al 99 % de $[6019,52 ; 6611,31]$ MW. Este hallazgo refuta, con una potencia estadística del 100 %, la consistencia del umbral operativo oficial de 14000 MW y establece una cota superior conservadora, demostrando que la inestabilidad de la red es una consecuencia de la degradación sistémica y no de un exceso de consumo.

Palabras clave: Monte Carlo, Error Tipo I, Intercalibración Satelital, Radiancia Nocturna, Heterocedasticidad, Inssegabilidad, Auditoría Energética, Inferencia Estocástica, Teledetección Nocturna (NTL), Censura de Datos, Robustez Paramétrica

1. Introducción

La evaluación del rendimiento de los sistemas industriales a gran escala se enfrenta con frecuencia a la opacidad institucional y a la censura de mediciones telemétricas directas. Ante este escenario, la matemática computacional ofrece herramientas robustas para la inferencia de variables latentes a través de *proxies* físicos, tales como la emisión fotométrica nocturna capturada mediante sensores espaciales.

Esta investigación adopta un flujo de trabajo computacional híbrido, integrando la potencia de Python para el procesamiento masivo de `\textit{Big Data}` geoespacial en la nube (mediante Google Earth Engine) y la rigurosidad estadística de R para el análisis inferencial, la simulación de Monte Carlo y el modelado de potencia estadística. Esta dualidad tecnológica permite cerrar la brecha entre la adquisición de datos crudos y la generación de un dictamen estadístico auditable.

La literatura científica reciente ha validado esta aproximación. Estudios fundamentales como el de Zhang, Li y Chen (2020) utilizaron la serie VIIRS para cuantificar la contracción de la actividad económica venezolana durante la crisis, reportando una pérdida del 30,37% en la suma de luz urbana. La presente investigación extiende este paradigma metodológico, superando el análisis descriptivo tradicional mediante la implementación de una auditoría estocástica integral. Mientras que los estudios precursores se limitaron a la correlación de tendencias, este trabajo aporta tres innovaciones fundamentales: i) la validación de supuestos paramétricos regionales mediante pruebas de heterocedasticidad formal; ii) la cuantificación del sesgo en modelos lineales mediante simulaciones de Monte Carlo; y iii) la integración de datos reales hasta mayo de 2026, capturando el comportamiento del sistema en la etapa post-pandemia.

La tesis se estructura en dos dimensiones articuladas. La primera aborda un pro-

blema teórico puro: la degradación del estadístico F de Fisher-Snedecor cuando los datos exhiben varianzas extremas. La segunda dimensión traslada este fundamento a una aplicación macroenergética crítica: la modelación de la demanda eléctrica real de Venezuela. Se demuestra que la red de transmisión nacional es un sistema intrínsecamente heterocedástico, lo cual invalida las aproximaciones inferenciales convencionales. Al articular la teoría de la demanda diversificada de Westinghouse con la teledetección nocturna, el modelo no solo refuta el discurso institucional de los 14000 MW, sino que explica, a través de fenómenos físicos como el Efecto Ferranti y la falta de inercia térmica, la causa raíz de la inestabilidad de voltaje que experimenta el sector doméstico. Con ello, esta investigación provee un método de auditoría independiente, transparente y científicamente auditable para el Sistema Eléctrico Nacional.

2. Antecedentes en la Auditoría mediante Teledetección (NTL)

La literatura científica reciente ha validado la radiancia nocturna (*Nighttime Lights*, NTL) como el *proxy* más robusto para la evaluación socioeconómica en entornos caracterizados por la opacidad estadística o la censura de datos oficiales.

Un antecedente fundamental es el estudio desarrollado por Zhang, Li y Chen (2020), publicado en el *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*. En dicha investigación, los autores utilizaron series temporales del sensor VIIRS para cuantificar la dinámica de la crisis venezolana durante el periodo 2012-2018. Mediante la aplicación del filtro de Hodrick-Prescott para descomponer la suma de luz urbana (SUL), los autores reportaron una pérdida del

30,37 % en la tendencia de la luz urbana (SULT), estableciendo correlaciones significativas ($R^2 > 0,91$) con indicadores macroeconómicos clave como la producción de crudo y el tipo de cambio.

La presente investigación extiende este paradigma metodológico superando el enfoque de correlación descriptiva tradicional. Mientras que los estudios precursores se limitaron al análisis de tendencias temporales mediante filtrado estándar, este trabajo implementa un marco de auditoría estocástica integral compuesto por:

1. **Análisis Paramétrico:** Validación de supuestos mediante pruebas de normalidad y heterocedasticidad regional.
2. **Simulación de Monte Carlo:** Cuantificación del error en el estadístico F ante el diseño muestral desbalanceado del sistema eléctrico.
3. **Inferencia Potencial:** Cálculo de la potencia estadística $(1 - \beta)$ y tamaño del efecto (d de Cohen) para refutar la consistencia del umbral operativo oficial de 14000 MW.

Esta evolución metodológica permite trascender la simple descripción de la contracción lumínica para ofrecer un dictamen técnico-científico sobre la fragilidad del Sistema Eléctrico Nacional.

3. Bases Teóricas y Diseño del Análisis Estocástico

Para garantizar la rigurosidad analítica de la auditoría macroenergética, el diseño de la investigación se fundamenta en la inferencia estadística para sortear la alta

censura telemétrica del sistema. Esta sección define el marco paramétrico, el sistema de hipótesis y la justificación teórica de los *proxies* físicos seleccionados.

3.1. Formulación Estocástica de las Hipótesis

En la estadística inferencial, la Hipótesis Nula (H_0) establece la afirmación institucional que se desea contrastar, mientras que la Hipótesis Alternativa (H_a) representa la presunción fundamentada en el análisis de variables latentes. El sistema de hipótesis se define formalmente como:

- H_0 (**Hipótesis Nula**): $\mu_{\text{demanda}} \geq 14000$ MW. El discurso oficial es estadísticamente consistente con los datos observables de carga servida.
- H_a (**Hipótesis Alternativa**): $\mu_{\text{demanda}} < 14000$ MW. La demanda real ha experimentado una contracción significativa inducida por factores demográficos e industriales, infiriendo que los esquemas de racionamiento obedecen a un colapso de la generación neta efectiva y no a un exceso de consumo.

3.2. El Método de Westinghouse y la Justificación Satelital

El análisis clásico de demanda máxima diversificada se rige por el teorema de Westinghouse, el cual establece que la carga concurrente de un sistema es estrictamente menor a la suma de sus demandas instaladas, ajustadas por factores de diversidad sectorial ($F_{\text{diversidad}}$):

$$D_{\text{max_sistema}} = \sum_{i=1}^n \frac{D_{\text{max_individual},i}}{F_{\text{diversidad},i}} \quad (1)$$

Para evaluar esta ecuación de forma tradicional, se requeriría acceso a las bitácoras del Despacho Nacional de Carga, incluyendo tasas de migración residencial,

factores de planta industrial en tiempo real y densidad comercial activa. Dada la opacidad institucional que censura estas variables, el cálculo micro-paramétrico resulta inviable.

Frente a esta limitación, la presente investigación propone la **Fotometría Satelital Nocturna (Nighttime Lights)** como un integrador macroscópico observable. La radiancia capturada por los sensores no es más que el subproducto electromagnético directo de la ecuación de Westinghouse aplicada en la realidad; es decir, la luz satelital representa la agregación física final de la carga verdaderamente diversificada y servida en los nodos geográficos.

3.3. Diseño del Experimento y Potencia Estadística

Para que el contraste adquiriera validez paramétrica sin depender de la telemétrica interna oficial, el modelo computacional debe extraer las mediciones satelitales aislando el ruido espacial y garantizando una base muestral robusta ($n \geq 60$ meses). El diseño experimental se rige por los siguientes tensores:

- **Nivel de Significancia (α):** Se establece en $\alpha = 0,01$. Representa la probabilidad máxima aceptada de rechazar equivocadamente H_0 (Error Tipo I).
- **Potencia Estadística ($1 - \beta$):** El bloque muestral y la magnitud del efecto esperado se estructuran para alcanzar una potencia superior al 0,90 (90%). Esto garantiza la capacidad matemática del algoritmo para detectar caídas de demanda sin incurrir en Error Tipo II.
- **Contexto Fenomenológico (Anillo Troncal de 765 kV):** Si el algoritmo estocástico demuestra consistentemente que la carga máxima servida es significativamente menor al umbral declarado, los apagones y las fluctuaciones de

frecuencia crónicas experimentadas en el anillo troncal de 765 kV no pueden atribuirse matemáticamente a un exceso de demanda de los usuarios, comprobando el déficit estructural del bloque de generación.

4. Simulación Estocástica de la Robustez del ANOVA

4.1. Formalismo Matemático

El Análisis de Varianza (ANOVA) fundamenta la validez de sus inferencias sobre el supuesto estricto de homocedasticidad. Para cuantificar la degradación del estadístico ante la violación de este axioma, se diseñó un algoritmo de Monte Carlo (5000 iteraciones) forzando la simulación bajo la hipótesis nula real ($\mu_1 = \mu_2 = \mu_3$). Se inyectó asimetría muestral y se manipuló el grado de heterocedasticidad definiendo la razón de varianzas $R = \sigma_{max}^2 / \sigma_{min}^2$.

4.2. Resultados del Análisis de Monte Carlo

La computación arrojó una degradación sistemática de la tasa empírica de Error Tipo I ($\hat{\alpha}$). Para una razón de varianzas severa ($R = 10$), el error empírico alcanzó el 0,222 frente a un nivel nominal de $\alpha = 0,05$. La demostración evidencia que la suma de cuadrados subestima el denominador del estadístico F cuando la varianza mayor se asocia a la muestra menor, inflando los falsos positivos sistemáticamente.




Figura 1: Sensibilidad del ANOVA

5. Auditoría Estocástica y Análisis de Robustez Paramétrica

Para garantizar la validez matemática de las estimaciones macroenergéticas satelitales, se desarrolló una auditoría estocástica integral sobre el vector de observaciones contemporáneas de radiancia (VIIRS 2021-2026). Este análisis permite evaluar los supuestos paramétricos y cuantificar la magnitud de la brecha operativa del Sistema Eléctrico Nacional (SEN).

5.1. Morfología de la Distribución y Supuestos Estocásticos

El análisis de momentos de orden superior sobre la radiancia regionalizada reveló una asimetría positiva ($S_k = 0,505$) y una curtosis de 1,884. La función de densidad empírica exhibe una concentración de masa probabilística en los deciles inferiores, indicativa de un estado base de baja energización y apagones crónicos, con una cola




Figura 2: Datos de Radiancia y Demanda

hacia la derecha que representa ciclos de recuperación de carga.

Esta desviación geométrica se confirma con la divergencia severa de los cuantiles empíricos en los gráficos Q-Q. Consecuentemente, la prueba de Shapiro-Wilk rechaza la hipótesis de normalidad con un nivel de significancia extremo ($p = 7,15 \times 10^{-7}$).

5.2. Heterocedasticidad Espacial: Racionamiento Asimétrico

La evaluación espacial expone la naturaleza asimétrica del despacho de carga. La región del Zulia presenta una varianza fuertemente comprimida en el límite inferior de radiancia, evidenciando un déficit estructural crónico. En contraste, Carabobo




Figura 3: Heterocedasticidad

exhibe una alta dispersión producto de la volatilidad en la energización de sus franjas industriales. La prueba formal de Levene confirma esta disparidad de varianzas de manera concluyente ($p = 3,90 \times 10^{-18}$).

Desde la perspectiva matemática, este hallazgo es crítico: valida empíricamente la necesidad de las simulaciones de Monte Carlo desarrolladas en la primera fase de esta investigación, demostrando que las herramientas clásicas de inferencia lineal están inherentemente sesgadas al analizar redes de potencia inestables.

5.3. Análisis de Tendencias Temporales Desagregadas

Para profundizar en la dinámica de la heterocedasticidad detectada, se procedió a desagregar el vector espacial y evaluar la evolución temporal de la radiancia de forma individual para los nodos de estudio. Esta descomposición permite aislar el comportamiento local que el agregado nacional suele ocultar.




Figura 4: Evolución temporal de la radiancia satelital (VIIRS) por región de estudio (2014-2026).

Como se observa en la Figura 4, las dinámicas regionales son marcadamente divergentes, lo cual valida la implementación de la constante de transferencia κ y el enfoque estocástico:

- **Región Occidental (Zulia):** Presenta la menor varianza en la serie contemporánea. Esto es consistente con un nodo que opera bajo un régimen de racionamiento estructural prolongado, actuando como un "suelo" de demanda. Los breves picos observados constituyen eventos transitorios de mejora, no una tendencia de recuperación.
- **Región Central (Carabobo):** Exhibe una volatilidad extrema. Este comportamiento estocástico se correlaciona con la intermitencia de su parque industrial; las oscilaciones violentas (picos y valles) representan la respuesta de la carga industrial a la inestabilidad del despacho en bloque.
- **Región Capital (Miranda):** Muestra un comportamiento de "meseta con oscilaciones estacionales, siendo el nodo que más preserva la inercia de consumo debido a su priorización en los esquemas de administración de carga nacional.




Figura 5: Línea base histórica de intensidad lumínica (DMSP) por región (1992-2013).

Al contrastar este comportamiento con la línea base histórica (Figura 5), se comprueba que el colapso de la carga servida post-2014 no muestra indicios de reversión en ninguna de las tres entidades, consolidando la estimación de demanda estancada proyectada por el modelo.

6. Análisis de Insseguridad y Límites de Subestimación

Una transición paramétrica que reduce el estimador de demanda de valores iniciales superiores a los 30000 MW (observados en modelos lineales sin filtro espacial) a una estimación robusta de $\hat{\mu} = 6315,42$ MW exige una demostración formal de ausencia de sesgo negativo. La solidez de esta estimación descansa sobre tres axiomas físicos y estocásticos:

6.1. Sensibilidad Radiométrica y Naturaleza de la Medida

La variable latente extraída de la banda DNB (Day/Night Band) del sensor NOAA-VIIRS no representa la *Demanda Potencial*, sino la *Demanda Real Servida*. A diferencia del sensor histórico DMSP-OLS, el VIIRS no sufre de sub-saturación en bajas intensidades y capta emisiones fotométricas hasta 100 veces más tenues. Por lo tanto, la baja radiancia observada obedece estrictamente a la ausencia física de flujo de potencia, descartando la subestimación por limitación óptica del sensor.

6.2. Depuración Espacial del Ruido de Combustión

La sobreestimación inicial del modelo crudo se atribuyó a la inclusión del agregador nacional completo, el cual asimilaba la radiancia masiva proveniente del *flaring* (quema de gas en pozos petroleros). Al restringir la máscara espacial a los centros de carga puramente socio-industrial (Carabobo, Miranda y Zulia), se eliminó el error sistemático positivo. Dado que no existen análogos industriales que emitan "seguridad", no hay mecanismo físico equivalente que introduzca un sesgo negativo en la matriz depurada.

6.3. Conservadurismo Matemático en la Ponderación (ω)

El argumento definitivo de insesgabilidad yace en la constante de extrapolación estructural ω . Basado en los registros inalterados del año 2000, se fijó que las regiones de estudio representaban $\omega = 0,45$ (45 %) de la demanda nacional:

$$D_{\text{Nacional},t} = \frac{D_{\text{Regional},t}}{\omega} = \frac{D_{\text{Regional},t}}{0,45} \quad (2)$$

Bajo la doctrina operativa actual del SEN, los esquemas de racionamiento pe-




Figura 6: Demanda Maxima

nalizan severamente a las regiones periféricas para preservar la estabilidad del eje Capital-Centro. Por consiguiente, la fracción real de la energía total que consumen estas 3 regiones en la actualidad es estrictamente mayor a su proporción histórica ($\omega_{\text{actual}} \gg 0,45$).

Al ser la extrapolación inversamente proporcional a ω , utilizar el ponderador histórico de 0,45 maximiza la función. Esto demuestra que la estimación obtenida es una **cota superior conservadora**. Si se ajustara ω a la realidad operativa del racionamiento contemporáneo, la demanda estimada decrecería aún más.

7. Conclusiones Generales

La presente investigación concluye con un dictamen estadístico categórico, fundamentado en la integración de 65 observaciones mensuales de telemétrica espacial contemporánea (actualizada hasta mayo de 2026). La aplicación de la constante de transferencia ajustada ($\kappa = 0,002988$) y el análisis paramétrico demuestran la inestabilidad física del sistema y la sobreestimación del discurso oficial, sustentándose en los siguientes hallazgos:

- **Diagnóstico de Inestabilidad (Heterocedasticidad y Asimetría):** La red de transmisión opera bajo un régimen de racionamiento asimétrico crónico, evidenciado por una morfología de distribución con asimetría marcadamente positiva ($S_k = 0,505$) y curtosis de 1,884. Las pruebas formales rechazan la normalidad (Shapiro-Wilk, $p = 7,15 \times 10^{-7}$) y confirman una heterocedasticidad espacial extrema (Levene, $p = 3,90 \times 10^{-18}$), validando de facto la pertinencia del abordaje estocástico propuesto.
- **Estimación Insesgada de la Demanda Servida ($\hat{\mu}$):** La demanda real del sistema ha tendido a estabilizarse en una banda oscilante en torno a una media actual de 6315,42 MW, rigurosamente acotada por un intervalo de confianza al 99 % de [6019,52 ; 6611,31] MW.
- **Magnitud de la Discrepancia (d de Cohen):** El distanciamiento entre la evidencia empírica satelital y el límite operativo institucional (14000 MW) arroja un tamaño del efecto absoluto de $|d| = 6,74$. Una divergencia superior a seis desviaciones estándar confirma matemáticamente que ambas cifras pertenecen a poblaciones estadísticas mutuamente excluyentes.

- **Potencia del Contraste ($1-\beta$):** La evaluación inferencial ($n = 65$, $\alpha = 0,01$) garantiza una potencia estadística empírica del 100 % ($1 - \beta \approx 1,000$).

A partir de esta arquitectura de datos, se garantiza analíticamente que el riesgo de cometer un Error Tipo II —aceptar equivocadamente la hipótesis institucional siendo esta falsa— es nulo. Desde la perspectiva de la matemática computacional, la probabilidad de que la red alcance los 14000 MW declarados es estadísticamente inexistente, lo que refuta de manera irrefutable la narrativa oficial.

En síntesis, este documento prueba de manera integral que las herramientas clásicas de inferencia lineal están inherentemente sesgadas al modelar redes de potencia inestables. Asimismo, ratifica la efectividad de la computación estocástica y de los algoritmos de intercalibración de variables latentes como metodologías robustas, precisas y transparentes para la auditoría independiente de sistemas físicos de gran escala.

7.1. Discusión sobre Fenómenos de Calidad de Energía y Estabilidad Sistémica

7.1.1. Dinámica de la Red Troncal de 765 kV y Estabilidad Sistémica

El análisis satelital que sitúa la demanda máxima servida en $\hat{\mu} = 6315,42$ MW permite reinterpretar las causas raíz de la inestabilidad observada en el anillo troncal de 765 kV. La literatura técnica asume que el anillo de 765 kV actúa como la columna vertebral del Sistema Interconectado Nacional (SIN), cuya función primordial es la transmisión de potencia desde la cuenca del Caroní hacia los centros de consumo.

La persistencia de las interrupciones del servicio, bajo una demanda tan contraída como la que arroja nuestro modelo ($|d| = 6,74$ frente al discurso oficial), revela que

las causas no son paramétricas (exceso de demanda), sino estructurales (degradación de la generación y falta de inercia). Los fenómenos esperados en la red troncal ante este escenario son:

- **Inestabilidad del Ángulo de Potencia:** Ante la desincorporación de la generación térmica base en el eje Centro-Occidente, la red de 765 kV opera con un margen de estabilidad transitoria extremadamente precario. Cualquier fluctuación en el despacho desde el Guri desencadena oscilaciones angulares que el sistema, carente de inercia local, no puede amortiguar, forzando la apertura de los interruptores de protección.
- **Colapso por Subfrecuencia (df/dt):** La respuesta automática del sistema ante la pérdida de una línea de 765 kV se traduce en el deslastre de carga por subfrecuencia. La continuidad de los cortes no refleja un consumo excesivo, sino la incapacidad de la red para mantener la frecuencia nominal (60 Hz) debido a la fragilidad del parque térmico que debería asistir al SIN.
- **Sobrevoltajes en Régimen de Carga Baja:** Paradójicamente, al operar con una demanda real significativamente menor a la diseñada (cercana a los 6300 MW), las líneas de 765 kV experimentan el *Efecto Ferranti*, elevando las tensiones de operación y obligando a la desconexión preventiva de ramales para evitar daños catastróficos en el parque de transformación.

En conclusión, el modelo estocástico demuestra que el anillo de 765 kV opera en un estado de equilibrio inestable. La cronicidad de los cortes es un subproducto directo de la asimetría entre la generación lejana (Guri) y una demanda servida que, aunque pequeña en términos macro, es lo suficientemente volátil para superar la capacidad de amortiguación de un sistema con inercia reducida.

7.2. Impacto Operativo: De la Macro-Inferencia a la Calidad de Potencia

La discrepancia revelada por el modelo estocástico entre la demanda real servida (~ 6315 MW) y el umbral oficial (14000 MW) no es un dato abstracto; posee una manifestación física directa en los niveles de tensión de la red de distribución. Los fenómenos de sobretensiones transitorias, oscilaciones de voltaje e inestabilidad en equipos terminales (iluminación y ventiladores) son *indicadores de campo* de la fragilidad del Sistema Interconectado Nacional.

7.2.1. Correlación entre Carga Servida e Inestabilidad de Voltaje

Las fluctuaciones observadas por los usuarios (subidas y bajadas de voltaje) son causadas por dos mecanismos fundamentales derivados de la operación del anillo de 765 kV en un estado de desequilibrio:

- **Efecto Ferranti y Baja Carga:** Como nuestro modelo demostró, la demanda real es significativamente baja frente al diseño original de la infraestructura. Esta sub-utilización de las líneas troncales genera el *Efecto Ferranti*, donde las capacitancias distribuidas de las líneas de ultra-alto voltaje provocan que el voltaje en los extremos receptores supere el nominal. Esto explica por qué los usuarios experimentan sobretensiones evidentes en sus luminarias, incluso en periodos de baja demanda.
- **Inestabilidad de Frecuencia y Regulación Automática:** La red, al carecer de la inercia rotacional aportada por las plantas térmicas base, es extremadamente sensible a cualquier variación de carga. Los reguladores automáticos de las subestaciones intentan compensar estas variaciones de forma brusca (pen-

duleo), provocando las oscilaciones de voltaje que los usuarios perciben en la velocidad de ventiladores y la intensidad de la iluminación.

- **Interconexión de Eventos:** Cada corte.^o reenganche.^a automático no es una medida de ahorro, sino una respuesta del sistema ante la incapacidad de la red de 765 kV para mantener un perfil de voltaje estable bajo una generación inestable. Estas maniobras generan transitorios (picos) que degradan el aislamiento de los equipos electrónicos domésticos.

En síntesis, los fenómenos de calidad de energía descritos son la consecuencia inevitable de operar un sistema de transmisión de gran escala diseñado para una demanda de 14000 MW, pero forzado a niveles de carga real cercanos a los 6300 MW con un parque generador térmico colapsado. La inestabilidad de voltaje es, por tanto, el síntoma de una infraestructura que "no encuentra su punto de equilibrio" frente a la intermitencia del despacho.

7.3. Sincronización Estocástica: Análisis de Correlación Cruzada Regional

Para descartar la hipótesis institucional de que las fluctuaciones de carga obedecen a fallas locales aisladas en las redes de distribución de baja tensión, se procedió a evaluar la sincronía del sistema mediante una matriz de correlación cruzada de Pearson sobre las series temporales de radiancia (VIIRS 2014-2026). El objetivo matemático es determinar si la inestabilidad energética es un fenómeno sistémico.




Figura 7: Matriz de correlación cruzada regional evidenciando el acoplamiento de las interrupciones del servicio.

La computación de la matriz (Figura 7) arrojó una covarianza estrictamente positiva y de alta magnitud entre todos los nodos geográficos. La región central exhibe el mayor acoplamiento ($r_{\text{Carabobo, Miranda}} = 0,835$), lo cual es físicamente coherente dado que ambas entidades dependen de la misma troncal de transmisión y carecen de independencia térmica base.

El nodo occidental (Zulia) mantiene una correlación fuerte con el centro ($r_{\text{Zulia, Carabobo}} = 0,738$; $r_{\text{Zulia, Miranda}} = 0,732$). Esta leve disminución frente al par central refleja el régimen de racionamiento crónico occidental: al ubicarse en el extremo receptor del anillo troncal, el Zulia sufre un efecto de "fijación en el límite inferior", permaneciendo desenergizado incluso durante las ventanas donde el centro experimenta recuperacio-

nes transitorias.

En términos de ingeniería de potencia, una correlación cruzada global superior a 0,73 demuestra matemáticamente que el Sistema Eléctrico Nacional opera como un bloque monolítico en déficit. Las oscilaciones lumínicas satelitales confirman que las interrupciones son maniobras sincronizadas de deslastre de carga dictadas por la incapacidad de generación, invalidando empíricamente la narrativa de fallas aisladas de distribución.

Apéndice A: Algoritmo de Extracción Geoespacial (Google Earth Engine)

A continuación, se presenta el código fuente desarrollado en Python mediante la API de Google Earth Engine, utilizado para la adquisición y vectorización de las matrices de radiancia nocturna histórica (DMSP-OLS) y contemporánea (NOAA-VIIRS).

```
1 import ee
2 import pandas as pd
3 from google.colab import files
4
5 # 1. Autenticacion e Inicializacion
6 ee.Authenticate()
7 ee.Initialize(project='estadistica-earth')
8
9 print("Construyendo geometrias...")
10
11 # 2. Definir las Regiones de Interes (Nacional + 3 Estados)
12 # Extraemos el poligono nacional
13 venezuela = ee.FeatureCollection("FAO/GAUL/2015/level0") \
14     .filter(ee.Filter.eq('ADMO_NAME', 'Venezuela')) \
15     .map(lambda f: f.set('Region', 'Nacional'))
16
17 # Extraemos los 3 estados
18 estados = ee.FeatureCollection("FAO/GAUL/2015/level1") \
19     .filter(ee.Filter.inList('ADM1_NAME', ['Carabobo', 'Zulia', '
20         Miranda'])) \
21     .map(lambda f: f.set('Region', f.get('ADM1_NAME')))
```

```

22 # Unimos todo en una sola coleccion de 4 poligonos
23 roi_combinada = venezuela.merge(estados)
24
25 #
26 # =====
27 # BLOQUE 1: EXTRACCION SATELITE MODERNO (VIIRS - MENSUAL - RADIANCIA
28 # )
29 #
30 # =====
31
32 print("Extrayendo datos de VIIRS (2014-2026) ...")
33
34 viirs = ee.ImageCollection("NOAA/VIIRS/DNB/MONTHLY_V1/VCMSLCFG") \
35     .select('avg_rad') \
36     .filterDate('2014-01-01', '2026-05-01')
37
38 def get_viirs_data(image):
39     means = image.reduceRegions(collection=roi_combinada, reducer=ee
40         .Reducer.mean(), scale=500)
41     date = image.date().format('YYYY-MM-dd')
42     return means.map(lambda f: f.set('Fecha', date))
43
44 viirs_features = viirs.map(get_viirs_data).flatten()
45 viirs_data = viirs_features.reduceColumns(ee.Reducer.toList(3), ['
46     Fecha', 'Region', 'mean']).values().get(0).getInfo()
47
48 df_viirs = pd.DataFrame(viirs_data, columns=['Fecha', 'Region', '
49     Radiancia_VIIRS'])
50 df_viirs['Fecha'] = pd.to_datetime(df_viirs['Fecha'])
51 df_viirs.to_csv('viirs_moderno_mensual.csv', index=False)

```



```

45
46 #
=====

47 # BLOQUE 2: EXTRACCION SATELITE HISTORICO (DMSP - ANUAL - LINEA BASE
    )
48 #
=====

49 print("Extrayendo datos historicos de DMSP (1992-2013) ...")
50
51 dmsp = ee.ImageCollection("NOAA/DMSP-OLS/NIGHTTIME_LIGHTS") \
52     .select('stable_lights') \
53     .filterDate('1992-01-01', '2014-01-01')
54
55 def get_dmsp_data(image):
56     means = image.reduceRegions(collection=roi_combinada, reducer=ee
57         .Reducer.mean(), scale=1000)
58     year = image.date().format('YYYY')
59     return means.map(lambda f: f.set('Anio', year))
60
61 dmsp_features = dmsp.map(get_dmsp_data).flatten()
62 dmsp_data = dmsp_features.reduceColumns(ee.Reducer.toList(3), ['Anio
63     ', 'Region', 'mean']).values().get(0).getInfo()
64
65 df_dmsp = pd.DataFrame(dmsp_data, columns=['Anio', 'Region', '
66     Intensidad_DMSP_0_a_63'])
67 df_dmsp.to_csv('dmsp_historico_anual.csv', index=False)
68
69 #
=====

```

```

67 # DESCARGA DE ARCHIVOS
68 #
=====
69 print("Extraccion_completada!_Descargando_archivos...")
70 files.download('viirs_moderno_mensual.csv')
71 files.download('dmsp_historico_anual.csv')

```

Listado de código 1: Script de extracción espacial de radiancia (DMSP y VIIRS)

Apéndice B: Metodología de Adquisición y Procesamiento Geoespacial

El presente estudio emplea la plataforma *Google Earth Engine* (GEE) como entorno de computación en la nube para la ingesta, normalización y reducción estadística de grandes volúmenes de datos geoespaciales multiespectrales.

B.1. Funcionamiento del Algoritmo de Extracción

El *script* desarrollado implementa un *pipeline* de procesamiento distribuido que consta de tres etapas críticas:

1. **Definición de Máscaras Espaciales:** A través de la librería *FAO/GAUL*, se definen geometrías de interés (ROI) que segmentan el territorio venezolano a escala nacional y regional (Carabobo, Miranda y Zulia). Estas geometrías actúan como "máscaras" que delimitan las áreas de cálculo computacional.

2. **Reducción Estadístico-Espacial (`reduceRegions`):** Esta función constituye el núcleo del algoritmo. Para cada imagen satelital, el sistema calcula la media aritmética (`ee.Reducer.mean()`) de los píxeles contenidos dentro de los límites de cada región. Este proceso suaviza el ruido aleatorio local y convierte datos *raster* (mapas) en series temporales escalares.
3. **Normalización Temporal y Vectorización:** El algoritmo normaliza las series temporales de dos misiones distintas:
 - **VIIRS-DNB:** Muestreo mensual con resolución de 500m, capturando la radiancia física en $\text{nW} \cdot \text{cm}^{-2} \cdot \text{sr}^{-1}$.
 - **DMSP-OLS:** Muestreo anual con resolución de 1000m, capturando una intensidad digital sin unidades físicas explícitas (escala 0 – 63).

B.2. Fundamentos de la Teledetección Nocturna (NTL)

La captura de datos por parte de los satélites NOAA-VIIRS y DMSP se basa en la radiometría de bandas infrarrojas visibles. Los satélites operan en órbita heliosíncrona, observando la Tierra en momentos de baja iluminación solar para registrar exclusivamente la radiación artificial (iluminación urbana, industrial y, en el caso de Venezuela, el *flaring* petrolero).




Figura 8: Representación del mecanismo de detección de luz nocturna del sensor DNB.

El sensor VIIRS utiliza un dispositivo de detección de luz de banda diurna/nocturna (*Day/Night Band*). A diferencia de las cámaras convencionales, este sensor posee una sensibilidad extrema, permitiendo diferenciar la tenue iluminación de un vecindario de la intensidad de una planta siderúrgica. Es esta capacidad de cuantificación fotométrica de alta resolución la que permite convertir píxeles de luz en una variable *proxy* de la demanda energética real.

B.3. Consideraciones de Validación

El proceso de extracción geoespacial garantiza que los datos resultantes sean estadísticamente representativos. Al integrar las series temporales mediante *Google Earth Engine*, se mitiga el sesgo de selección y se asegura que cada promedio regional

refleje la carga lumínica total, independientemente de la cobertura nubosa, gracias a los algoritmos de filtrado mensual incluidos en los productos VIIRS.

B.4. Argumentación Técnica

Se sintetizan los argumentos técnicos sobre la metodología empleada:

- **Sobre la infraestructura GEE:** La potencia de la plataforma radica en que no descargamos imágenes de petabytes de tamaño, sino que enviamos el algoritmo a los datos en la nube, eliminando el error humano en reproyecciones y cálculos espaciales.
- **Diferencia de resolución:** La discrepancia entre 500m (VIIRS) y 1000m (DMSP) es compensada matemáticamente mediante el coeficiente de transferencia κ , diseñado para armonizar ambas escalas.
- **Validez de la banda DNB:** La banda DNB (500 a 900 nm) es la medida física más cercana a la actividad eléctrica humana, ya que coincide con el espectro de emisión de las luminarias de sodio, LED y mercurio.

Referencias

- [1] Zhang, L., Li, X., & Chen, F. (2020). *Spatiotemporal Analysis of Venezuela's Nighttime Light During the Socioeconomic Crisis*. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 13, 2396-2404.
- [2] Gorelick, N., Hancher, M., Dixon, M., Ilyushchenko, S., Thau, D., & Moore, R. (2017). *Google Earth Engine: Planetary-scale geospatial analysis for everyone*. Remote Sensing of Environment, 202, 18-27.

- [3] Elvidge, C. D., Baugh, K., Zhizhin, M., Hsu, F. C., & Ghosh, T. (2017). *VIIRS night-time lights*. International Journal of Remote Sensing, 38(21), 5860-5879.
- [4] Cohen, J. (1988). *Statistical Power Analysis for the Behavioral Sciences* (2nd ed.). Routledge.
- [5] Montgomery, D. C. (2017). *Design and Analysis of Experiments* (9th ed.). John Wiley & Sons.
- [6] Gönen, T. (2014). *Electric Power Distribution System Engineering* (3rd ed.). CRC Press.
- [7] R Core Team. (2026). *R: A language and environment for statistical computing*. R Foundation for Statistical Computing, Vienna, Austria.

Apendice C: Implementación Computacional en R

Esta sección documenta los algoritmos desarrollados en el entorno *R* (*v.4.x*) para la ejecución de las pruebas estocásticas, inferenciales y la generación de la suite diagnóstica.

C.1. Simulación de Monte Carlo (Robustez del ANOVA)

```

1 #
2 # PROYECTO 1: SENSIBILIDAD DEL ANOVA
3 # Caso de Estudio: Demanda Eléctrica Regional (Proxy: Radiancia
  VIIRS)

```

```

4  #
    =====

5
6  # LIBRERÍAS (Instálalas con install.packages("ggplot2") si no las
    tienes)
7  library(ggplot2)
8  library(dplyr)
9
10 #
    -----

11 # FASE 1: INGESTA DE DATOS Y ESTADÍSTICA DESCRIPTIVA (Línea Base)
12 #
    -----

13 cat("Cargando datos satelitales...\n")
14 datos_viirs <- read.csv("viirs_moderno_mensual.csv")
15
16 # Filtrar datos de los 3 estados (excluyendo el agregado Nacional)
17 datos_estados <- subset(datos_viirs, Region %in% c("Carabobo", "
    Miranda", "Zulia"))
18
19 # Calcular la desviación estándar (ruido/inestabilidad) real de cada
    estado
20 stats_reales <- datos_estados %>%
21   group_by(Region) %>%
22   summarise(
23     Media = mean(Radiancia_VIIRS),
24     Varianza = var(Radiancia_VIIRS),
25     Desviacion_Std = sd(Radiancia_VIIRS)

```

```

26 )
27
28 print("Estadísticas_Reales_Observadas_(VIIRS_2014-2026):")
29 print(stats_reales)
30
31 # Tomaremos la varianza más baja observada (suele ser Miranda) como
   nuestra varianza "base"
32 # para inyectarla en la simulación.
33 sd_base <- min(stats_reales$Desviacion_Std)
34
35 #
   -----
36 # FASE 2: SIMULACIÓN DE MONTE CARLO (El requerimiento de la
   asignación)
37 #
   -----
38 # OBJETIVO: Evaluar la Tasa de Error Tipo I bajo Heterocedasticidad
   y Desbalance.
39 # REGLA DE ORO DEL ERROR TIPO I: La Hipótesis Nula DEBE ser cierta.
40 # Por tanto, forzaremos a que las medias de los 3 grupos sean
   matemáticamente idénticas,
41 # y solo manipularemos las varianzas (simulando la inestabilidad
   eléctrica) y los tamaños de muestra.
42
43 num_simulaciones <- 5000
44 alfa <- 0.05
45 mu_comun <- 5.0 # Media sintética idéntica para los 3 grupos
46

```



```

47 # Parámetros de Desbalance Muestral (n diferentes por fallas en
    sensores/data)
48 n_miranda <- 120 # Muestra completa (10 años x 12 meses)
49 n_carabobo <- 60 # Muestra reducida a la mitad
50 n_zulia <- 30 # Desbalance severo (mucha pérdida de datos)
51
52 # Ratios de Varianza a evaluar (1x, 2x, 5x, 10x la varianza base)
53 ratios_var <- c(1, 2, 5, 10)
54 resultados_error <- numeric(length(ratios_var))
55
56 cat("\nIniciando Simulación de Monte Carlo(", num_simulaciones, "
    iteraciones por ratio)... \n", sep="")
57
58 # Bucle sobre los diferentes niveles de heterocedasticidad
59 for(i in 1:length(ratios_var)) {
60
61     rechazos_H0 <- 0
62     ratio <- ratios_var[i]
63
64     # Asignamos las desviaciones estándar.
65     # A Zulia (la muestra más pequeña) le asignamos la varianza más
        grande (El peor escenario para ANOVA)
66     sd_1 <- sd_base
67     sd_2 <- sd_base * sqrt(2) # Varianza intermedia
68     sd_3 <- sd_base * sqrt(ratio) # Varianza multiplicada por el ratio
69
70     for(j in 1:num_simulaciones) {
71         # 1. Generación de datos sintéticos
72         y_miranda <- rnorm(n_miranda, mean = mu_comun, sd = sd_1)
73         y_carabobo <- rnorm(n_carabobo, mean = mu_comun, sd = sd_2)
74         y_zulia <- rnorm(n_zulia, mean = mu_comun, sd = sd_3)

```

```

75
76 # 2. Estructuración
77 valores <- c(y_miranda, y_carabobo, y_zulia)
78 grupos  <- factor(rep(c("Miranda", "Carabobo", "Zulia"), times =
      c(n_miranda, n_carabobo, n_zulia)))
79 df_sim  <- data.frame(Radiancia = valores, Estado = grupos)
80
81 # 3. Prueba ANOVA
82 modelo <- aov(Radiancia ~ Estado, data = df_sim)
83 p_valor <- summary(modelo)[[1]][["Pr(>F)"]][1]
84
85 # 4. Conteo de Error Tipo I (Rechazamos H0 incorrectamente)
86 if(p_valor < alfa) {
87     rechazos_H0 <- rechazos_H0 + 1
88 }
89 }
90
91 # Registrar la proporción de error para este ratio
92 resultados_error[i] <- rechazos_H0 / num_simulaciones
93 cat("Ratio de Varianza:", ratio, "| Tasa Error Tipo I:",
      resultados_error[i], "\n")
94 }
95
96 #
97
98 # FASE 3: INFORME TÉCNICO Y GRÁFICAS
99 #

```

```

99 df_resultados <- data.frame(Ratio_Varianza = ratios_var, Error_Tipo_
    I = resultados_error)
100
101 grafica <- ggplot(df_resultados, aes(x = Ratio_Varianza, y = Error_
    Tipo_I)) +
102   geom_line(color = "#004B87", linewidth = 1.2) +
103   geom_point(color = "#E31837", size = 4) +
104   geom_hline(yintercept = alfa, linetype = "dashed", color = "black"
    , linewidth = 1) +
105   scale_y_continuous(labels = scales::percent_format(accuracy = 1))
    +
106   labs(
107     title = "Sensibilidad del ANOVA ante Violación de Supuestos",
108     subtitle = "Efecto combinado de Heterocedasticidad y Desbalance
        Muestral",
109     x = "Razón de Varianzas Máxima/Mínima",
110     y = "Tasa de Error Tipo I (Falsos Positivos)"
111   ) +
112   theme_minimal() +
113   theme(
114     plot.title = element_text(face = "bold", size = 14),
115     axis.title = element_text(face = "bold")
116   )
117
118 print(grafica)

```

Listado de código 2: Script de simulación de Monte Carlo para validación de Error Tipo I

C.2. Auditoría Estocástica y Calibración Fotométrica

```

1  #
    =====

2  # SCRIPT MAESTRO: CALIBRACIÓN ESTOCÁSTICA DE DEMANDA ELÉCTRICA
3  # Versión 8.0: Auditoría Estadística Integral y Visualización
    Analítica
4  #
    =====

5
6  # 0. CARGA DE LIBRERÍAS
7  library(dplyr)
8  library(stringr)
9  library(ggplot2)
10 library(car)      # Para Levene Test (Heterocedasticidad)
11 library(pwr)      # Para Potencia Estadística (1 - Beta)
12 library(moments)  # Para Asimetría y Curtosis
13
14 cat("\n[1/5]▯INGESTANDO▯Y▯SANEANDO▯DATOS...▯\n")
15 df_dmsp <- read.csv("dmsp_historico_anual.csv") %>% mutate(Anio =
    as.numeric(as.character(Anio)))
16 df_viirs <- read.csv("viirs_moderno_mensual.csv") %>%
17   mutate(
18     Anio = as.numeric(format(as.Date(Fecha), "%Y")),
19     Region = str_replace(as.character(Region), "_mean", "")
20   )
21
22 regiones_estudio <- c("Carabobo", "Miranda", "Zulia")
23 df_dmsp_reg <- df_dmsp %>% filter(Region %in% regiones_estudio)
24 df_viirs_reg <- df_viirs %>% filter(Region %in% regiones_estudio)

```

```

25
26
27 cat("[2/5] FASE 1: ANÁLISIS EXPLORATORIO Y DIAGNÓSTICO DE SUPUESTOS
    ... \n")
28 # Analizamos la distribución de radiancia en el bloque contemporáneo
    (2021-2023)
29 df_diagnostico <- df_viirs_reg %>% filter(Anio %in% c(2021, 2022,
    2023, 2024, 2025, 2026))
30
31 # Momentos de orden superior
32 asimetria <- skewness(df_diagnostico$Radiancia_VIIRS)
33 curtosis <- kurtosis(df_diagnostico$Radiancia_VIIRS)
34
35 # Pruebas Formales
36 test_normalidad <- shapiro.test(df_diagnostico$Radiancia_VIIRS)
37 test_varianza <- leveneTest(Radiancia_VIIRS ~ as.factor(Region),
    data = df_diagnostico)
38
39 cat("\n-> Asimetría (Skewness):", round(asimetria, 3), "(>0 indica
    cola pesada a la derecha) \n")
40 cat("\n-> Curtosis:", round(curtosis, 3), "\n")
41 cat("\n-> P-valor Shapiro-Wilk (Normalidad):", signif(test_
    normalidad$p.value, 3), "\n")
42 cat("\n-> P-valor Levene (Homocedasticidad):", signif(test_varianza$
    'Pr(>F)'[1], 3), "\n")
43
44
45 cat("\n[3/5] FASE 2: CALIBRACIÓN FOTOMÉTRICA REGIONAL ... \n")
46 demanda_regiones_2000 <- 12300 * 0.45
47 luz_regiones_2000 <- sum(df_dmisp_reg$Intensidad_DMSP_0_a_63[df_dmisp_
    reg$Anio == 2000])

```

```

48 luz_regiones_2013 <- sum(df_dmosp_reg$Intensidad_DMSP_0_a_63[df_dmosp_
    reg$Anio == 2013])
49
50 factor_contraccion_reg <- luz_regiones_2013 / luz_regiones_2000
51 demanda_regiones_eq_2013 <- demanda_regiones_2000 * factor_
    contraccion_reg
52
53 # Extracción de la media con propagación de error estándar
54 luz_viirs_2014_mensual <- df_viirs_reg %>%
55   filter(Anio == 2014) %>% group_by(Fecha) %>%
56   summarise(Total = sum(Radiancia_VIIRS), .groups="drop")
57
58 luz_viirs_reg_2014 <- mean(luz_viirs_2014_mensual$Total)
59 error_estandar_luz <- sd(luz_viirs_2014_mensual$Total) / sqrt(12)
60
61 kappa_regional <- luz_viirs_reg_2014 / demanda_regiones_eq_2013
62 # Aplicación básica del Método Delta para la incertidumbre de Kappa
63 se_kappa <- error_estandar_luz / demanda_regiones_eq_2013
64
65
66 cat("\n[4/5] FASE 3: INFERENCIA ESTOCÁSTICA Y TAMAÑO DEL EFECTO...\n
    ")
67 df_actual_bloque <- df_viirs_reg %>%
68   filter(Anio %in% c(2021, 2022, 2023,2024,2025,2026)) %>%
69   group_by(Fecha) %>%
70   summarise(Radiancia_Combinada = sum(Radiancia_VIIRS), .groups = "
    drop") %>%
71   mutate(Demanda_Nacional_MW = (Radiancia_Combinada / kappa_regional
    ) / 0.45)
72
73 n_muestras <- nrow(df_actual_bloque)

```

```

74 predicción_demanda <- t.test(df_actual_bloque$Demanda_Nacional_MW,
    conf.level = 0.99)
75 demanda_media <- predicción_demanda$estimate
76 s_demanda <- sd(df_actual_bloque$Demanda_Nacional_MW)
77
78 # Tamaño del efecto (d de Cohen) frente a H0 = 14000 MW
79 mu_0 <- 14000
80 d_cohen <- (demanda_media - mu_0) / s_demanda
81
82 # Potencia Estadística Computada (1 - Beta)
83 potencia <- pwr.t.test(n = n_muestras, d = d_cohen, sig.level =
    0.01, type = "one.sample")$power
84
85
86 cat("\n
    =====\n
    n")
87 cat("REPORTE_FINAL_DE_AUDITORÍA_ESTADÍSTICA_(NIVEL_POSTGRADO)\n")
88 cat("
    =====\n
    n")
89 cat("1. PARÁMETROS INFERENCIALES\n")
90 cat("Media Estimada (MW):", round(demanda_media, 2), "\n")
91 cat("IC 99% Inferior:", round(predicción_demanda$conf.int
    [1], 2), "\n")
92 cat("IC 99% Superior:", round(predicción_demanda$conf.int
    [2], 2), "\n")
93 cat("\n2. ANÁLISIS DE ROBUSTEZ Y POTENCIA\n")
94 cat("Coeficiente Kappa:", signif(kappa_regional, 4), " ",
    signif(se_kappa, 3), "\n")

```

```

95 cat("    Tamaño del Efecto (d):", round(d_cohen, 2), "(Efecto de
    discrepancia gigantesco)\n")
96 cat("    Potencia (1-Beta):", round(potencia * 100, 4), "% (
    Probabilidad de acierto)\n")
97 cat("\n3. DICTAMEN DE CONSISTENCIA OFICIAL (H0:  $\mu \geq 14000$ )\n")
98 cat("    Al rechazar H0 con una potencia del 100%, se demuestra de
    manera\n")
99 cat("    irrefutable que la capacidad de demanda real es
    estructuralmente\n")
100 cat("    inferior a la narrativa oficial.\n")
101 cat("
    =====\n")
102
103 cat("\n[5/5] GENERANDO VISUALIZACIÓN ANALÍTICA (Revisar panel 'Plots
    ')\n")
104
105 # Gráfico 1: Demostración Visual de Heterocedasticidad (Boxplot)
106 plot_diagnostico <- ggplot(df_diagnostico, aes(x = Region, y =
    Radiancia_VIIRS, fill = Region)) +
107   geom_boxplot(alpha = 0.7, outlier.color = "red", outlier.size = 3)
108   +
109   theme_minimal() +
110   labs(title = "Diagnóstico de Dispersión Regional (2021-2023)",
    subtitle = "Evidencia empírica de varianzas desiguales (
    Heterocedasticidad)",
111     y = "Radiancia Física (VIIRS)", x = "") +
112   theme(legend.position = "none", plot.title = element_text(face="
    bold"))
113

```



```

114 # Imprimimos el primer gráfico (pausa para que R lo procese si se
    usa RStudio)
115 print(plot_diagnostico)
116
117 # Gráfico 2: Serie de Tiempo de la Demanda Nacional Estimada con
    Bandas de Confianza
118 # Convertimos Fecha a Date para el eje X
119 df_actual_bloque$Fecha_Date <- as.Date(paste0(df_actual_bloque$Fecha
    , "-01"))
120
121 # Calculamos el error estándar de la media para graficar la banda
122 se_mean <- s_demanda / sqrt(n_muestras)
123 t_critico <- qt(0.995, df = n_muestras - 1) # Para 99% de confianza
    (dos colas)
124
125 plot_serie <- ggplot(df_actual_bloque, aes(x = Fecha_Date, y =
    Demanda_Nacional_MW)) +
126   geom_rect(aes(xmin = min(Fecha_Date), xmax = max(Fecha_Date),
127     ymin = prediccion_demanda$conf.int[1],
128     ymax = prediccion_demanda$conf.int[2]),
129     fill = "#B0C4DE", alpha = 0.5) +
130   geom_line(color = "#004B87", linewidth = 1.2) +
131   geom_point(color = "#004B87", size = 2) +
132   geom_hline(yintercept = mu_0, linetype = "dashed", color = "#
    E31837", linewidth = 1.5) +
133   geom_hline(yintercept = demanda_media, linetype = "dotted", color
    = "black", linewidth = 1) +
134   annotate("text", x = min(df_actual_bloque$Fecha_Date), y = mu_0 +
    300,
135     label = "Discurso Oficial (14,000 MW)", color = "#E31837"
    , hjust = 0, fontface = "bold") +

```

```

136   annotate("text", x = min(df_actual_bloque$Fecha_Date), y = demanda
137       _media + 300,
138       label = "Demanda_Real_Estimada(~5,800 MW)", color = "
139           black", hjust = 0, fontface = "bold") +
140   scale_y_continuous(limits = c(4000, 15000), breaks = seq(4000,
141       15000, by=2000)) +
142   theme_minimal() +
143   labs(title = "Inferencia_Estocástica_de_la_Demanda_Máxima_del_SEN"
144       ,
145       subtitle = "Contraste_empírico_entre_la_narrativa_oficial_y_
146           la_medición_satelital",
147       x = "Período_(Mensual)", y = "Megavatios_(MW)") +
148   theme(plot.title = element_text(face="bold", size=14),
149       axis.text.x = element_text(angle = 45, hjust = 1))
150
151 # Recomendamos al usuario usar una ventana de visualización (X11 o
152   RStudio Plots)
153 dev.new() # Abre una nueva ventana para no sobrescribir el boxplot
154 print(plot_serie)
155
156 cat("\nEjecución_finalizada_con_éxito._Se_han_generado_dos_gráficas_
157     analíticas.\n")
158
159 #
160     =====
161
162 # SCRIPT COMPLEMENTARIO V8.1: SUITE DE DIAGNÓSTICO VISUAL AVANZADO
163 #
164     =====
165
166 library(ggplot2)

```

```

156 library(patchwork) # Para unir múltiples gráficos en un solo panel
157
158 cat("\nGenerando Suite de Diagnóstico Analítico...\n")
159
160 # Gráfico A: Densidad de Probabilidad (Comprobando la Asimetría)
161 plot_densidad <- ggplot(df_diagnostico, aes(x = Radiancia_VIIRS)) +
162   geom_density(fill = "#4682B4", alpha = 0.6, color = "#000080",
163     linewidth = 1) +
164   geom_vline(aes(xintercept = mean(Radiancia_VIIRS)), color = "red",
165     linetype = "dashed", linewidth = 1) +
166   theme_minimal() +
167   labs(title = "A) Función de Densidad de Probabilidad",
168     subtitle = "Cola pesada a la derecha (Asimetría positiva)",
169     x = "Radiancia Física", y = "Densidad")
170
171 # Gráfico B: Gráfico Q-Q (Comprobando el test de Shapiro-Wilk)
172 plot_qq <- ggplot(df_diagnostico, aes(sample = Radiancia_VIIRS)) +
173   stat_qq(color = "#E31837", alpha = 0.6) +
174   stat_qq_line(color = "black", linewidth = 1) +
175   theme_minimal() +
176   labs(title = "B) Gráfico Q-Q de Normalidad",
177     subtitle = "Desviación extrema en las colas teóricas",
178     x = "Cuantiles Teóricos", y = "Cuantiles Muestrales")
179
180 # Gráfico C: Gráfico de Violín (Distribución interna por Región)
181 plot_violin <- ggplot(df_diagnostico, aes(x = Region, y = Radiancia_
182   VIIRS, fill = Region)) +
183   geom_violin(alpha = 0.7, trim = FALSE) +
184   geom_boxplot(width = 0.1, fill = "white", outlier.shape = NA) +
185   theme_minimal() +
186   labs(title = "C) Gráfico de Violín Regional",

```

```

184     subtitle = "Densidad_bimodal_y_heterocedasticidad",
185     x = "", y = "Radiancia") +
186     theme(legend.position = "none")
187
188 # Gráfico D: Tendencia de Carga Mensual (Suavizado LOESS)
189 plot_tendencia <- ggplot(df_actual_bloque, aes(x = Fecha_Date, y =
190     Demanda_Nacional_MW)) +
191     geom_point(color = "gray50", alpha = 0.6) +
192     geom_smooth(method = "loess", span = 0.3, color = "#008000", fill
193         = "#98FB98", alpha = 0.4) +
194     theme_minimal() +
195     labs(title = "D)_Tendencia_No_Lineal_(LOESS)",
196         subtitle = "Suavizado_de_la_demanda_en_36_meses",
197         x = "Fecha", y = "Demanda_Estimada_(MW)")
198
199 # Ensamblaje del Panel Multigráfico con Patchwork
200 panel_completo <- (plot_densidad | plot_qq) / (plot_violin | plot_
201     tendencia) +
202     plot_annotation(
203         title = 'Auditoría_Estocástica_de_Datos_de_Radiancia_y_Demanda',
204         subtitle = 'Análisis_de_Supuestos_Paramétricos_y_Morfología_de_
205             Distribución',
206         theme = theme(plot.title = element_text(size = 16, face = "bold"
207             ))
208     )
209
210 dev.new(width=12, height=8) # Abre una ventana más grande para
211     acomodar el panel
212 print(panel_completo)
213
214 cat("Suite_visual_generada_con_éxito.\n")

```

Apendice D: SCRIPT DE ANÁLISIS DESCRIPTIVO Y CORRELACIÓN CRUZADA (PYTHON)

```
1  #
   -----
2  # SCRIPT DE ANÁLISIS DESCRIPTIVO Y CORRELACIÓN CRUZADA (PYTHON)
3  #
   -----
4  import pandas as pd
5  import matplotlib.pyplot as plt
6  import seaborn as sns
7
8  # 1. Ingesta y preparación de datos
9  df_viirs = pd.read_csv('viirs_moderno_mensual.csv')
10 df_viirs['Fecha'] = pd.to_datetime(df_viirs['Fecha'])
11 df_dmsp = pd.read_csv('dmsp_historico_anual.csv')
12
13 regiones = ['Carabobo', 'Miranda', 'Zulia']
14 df_viirs_reg = df_viirs[df_viirs['Region'].isin(regiones)]
15 df_dmsp_reg = df_dmsp[df_dmsp['Region'].isin(regiones)]
16
17 sns.set_theme(style="whitegrid")
18
19 # 2. Generación de FacetGrid (Series de Tiempo Regionales)
```

```

20 g1 = sns.FacetGrid(df_viirs_reg, col="Region", col_wrap=3, height=4,
    sharey=False)
21 g1.map(sns.lineplot, "Fecha", "Radiancia_VIIRS")
22 g1.set_titles("{col_name}")
23 g1.set_axis_labels("Fecha", "Radiancia_(VIIRS)")
24 plt.savefig('viirs_por_region.png')
25
26 # 3. Estructuración Matricial (Pivot) para Correlación
27 df_pivot = df_viirs_reg.pivot(index='Fecha', columns='Region',
    values='Radiancia_VIIRS')
28
29 # 4. Cálculo Estocástico de la Matriz de Correlación de Pearson
30 corr_matrix = df_pivot.corr()
31
32 # 5. Generación de Visualización (Heatmap Analítico)
33 plt.figure(figsize=(6, 5))
34 sns.heatmap(corr_matrix, annot=True, cmap='coolwarm', vmin=0, vmax
    =1, fmt=".3f", linewidths=.5)
35 plt.title('Matriz_de_Correlación_Cruzada_Regional_(VIIRS_2014-2026)')
36 plt.tight_layout()
37 plt.savefig('correlacion_cruzada.png')

```