

Reporte Parcial - Vía A: Analisis Espacio-Climatico

Reporte Parcial - Vía A: Análisis de Covarianza Espacio-Climática (ERA5 vs. VIIRS)

Autor: Ing. Melvin Eleazar Padilla Valdez

Junio de 2026

1. FUNDAMENTACIÓN TEÓRICA

En la ingeniería de sistemas de potencia, la demanda eléctrica en zonas tropicales está fuertemente acoplada a las variables climatológicas. El principio termodinámico dicta que, ante un incremento en la temperatura ambiental, la carga por refrigeración térmica (compresores de aire acondicionado) se eleva, exigiendo a la red una mayor inyección de potencia activa (MW) y reactiva (MVAR).

El objetivo de esta fase es calcular la covarianza entre la temperatura ambiental y la radiancia nocturna (proxy de la demanda servida). En un sistema eléctrico estable, la correlación debe ser estrictamente positiva. Si la correlación es negativa (inelasticidad), se demuestra matemáticamente que el sistema es incapaz de absorber el pico de demanda térmica, lo que obliga al Despacho Nacional a ejecutar deslastres de carga (apagones programados) para evitar el colapso de la red de transmisión.

2. INGESTA DE DATOS CLIMÁTICOS (PYTHON / API GOOGLE EARTH ENGINE)

Para obtener vectores climatológicos de alta precisión, se diseñó un script en Python que interactúa con la plataforma de Big Data aeroespacial Google Earth Engine. Se extrajo la temperatura media mensual a 2 metros de altura utilizando el dataset ECMWF/ERA5_LAND (resolución espacial de 11 km).

```
# SCRIPT DE EXTRACCIÓN DE TEMPERATURA CLIMÁTICA (ERA5 LAND)
import ee
import pandas as pd

# 1. Autenticación e Inicialización
ee.Authenticate()
ee.Initialize(project='estadistica-earth')

# 2. Definición de Regiones (Carabobo, Miranda, Zulia)
estados = ee.FeatureCollection("FAO/GAUL/2015/level1") \
    .filter(ee.Filter.inList('ADM1_NAME', ['Carabobo', 'Zulia', 'Miranda'])) \
    .map(lambda f: f.set('Region', f.get('ADM1_NAME')))

# 3. Ingesta del Dataset Climático ERA5 (ECMWF)
era5 = ee.ImageCollection("ECMWF/ERA5_LAND/MONTHLY_AGGR") \
    .select('temperature_2m') \
    .filterDate('2014-01-01', '2026-05-01')

# 4. Función de Reducción y Conversión Térmica
def get_temperature_data(image):
    means = image.reduceRegions(
        collection=estados, reducer=ee.Reducer.mean(), scale=11132
    )
    date = image.date().format('YYYY-MM-dd')

    # Conversión Kelvin a Celsius: T(C) = T(K) - 273.15
    def process_feature(f):
        temp_celsius = ee.Number(f.get('mean')).subtract(273.15)
        return f.set('Temperatura_C', temp_celsius).set('Fecha', date)

    return means.map(process_feature)

# 5. Ejecución, Vectorización y Exportación
era5_features = era5.map(get_temperature_data).flatten()
```

Reporte Parcial - Via A: Analisis Espacio-Climatico

```
era5_data = era5_features.reduceColumns(
    ee.Reducer.toList(3), ['Fecha', 'Region', 'Temperatura_C']
).values().get(0).getInfo()

df_era5 = pd.DataFrame(era5_data, columns=['Fecha', 'Region', 'Temperatura_C'])
df_era5.to_csv('era5_temperatura_mensual.csv', index=False)
```

3. ANÁLISIS COMPUTACIONAL Y REGRESIÓN LINEAL (LENGUAJE R)

Posterior a la extracción, se procesaron las matrices en el entorno estadístico R. Mediante el uso de las librerías dplyr y ggplot2, se acopló la matriz climática con la matriz fotométrica (VIIRS) para calcular los coeficientes de correlación de Pearson (r) por nodo geográfico.

```
# SCRIPT DE ANÁLISIS ESTADÍSTICO EN R
library(dplyr)
library(ggplot2)
library(stringr)

# 1. Carga y estandarización de matrices
df_viirs <- read.csv("viirs_moderno_mensual.csv") %>%
  mutate(Fecha = as.Date(Fecha), Region = str_trim(str_replace(Region, "_mean", "")))

df_era5 <- read.csv("era5_temperatura_mensual.csv") %>%
  mutate(Fecha = as.Date(Fecha), Region = str_trim(Region))

# 2. Acoplamiento Estocástico (Inner Join)
regiones_estudio <- c("Carabobo", "Miranda", "Zulia")
df_acoplado <- inner_join(df_viirs, df_era5, by = c("Fecha", "Region")) %>%
  filter(Region %in% regiones_estudio)

# 3. Cálculo de Correlación de Pearson
correlaciones <- df_acoplado %>%
  group_by(Region) %>%
  summarise(r_Pearson = cor(Temperatura_C, Radiancia_VIIRS, use = "complete.obs"))
print(correlaciones)

# 4. Generación de Gráfica (Regresión Lineal Simple)
plot_clima <- ggplot(df_acoplado, aes(x = Temperatura_C, y = Radiancia_VIIRS, color = Region)) +
  geom_point(alpha = 0.6, size = 2) +
  geom_smooth(method = "lm", se = TRUE, linewidth = 1.2) +
  facet_wrap(~ Region, scales = "free") +
  theme_minimal() +
  labs(
    title = "Impacto del Estrés Térmico en la Estabilidad de la Red (2014-2026)",
    x = "Temperatura Media Mensual (C)",
    y = "Radiancia Física (VIIRS)"
  )
print(plot_clima)
```

4. VISUALIZACIÓN Y RESULTADOS ESTADÍSTICOS

Interpretación de la Matriz de Correlación de Pearson:

- Carabobo: $r = -0.032$ (Inelástico, tendencia negativa)
- Zulia: $r = -0.079$ (Inelástico, tendencia negativa)
- Miranda: $r = +0.181$ (Elástico, tendencia positiva)

5. CONCLUSIÓN DE LA VÍA A

Reporte Parcial - Via A: Analisis Espacio-Climatico

El análisis numérico demuestra una anomalía matemática severa. En el extremo receptor occidente (Zulia) y en el centro industrial (Carabobo), la correlación es negativa. Esto prueba empíricamente que ante el aumento del calor (pico térmico), el sistema sufre una caída en la demanda servida (menor radiancia).

Físicamente, esto ocurre porque la inyección masiva de demanda inductiva (aire acondicionado) sin soporte de generación local supera los límites de estabilidad de tensión, forzando cortes de energía programados. Por su parte, la leve pendiente positiva en Miranda ($r = +0.181$) revalida estadísticamente la hipótesis de que el Despacho Nacional prioriza la estabilidad de la región capital, permitiéndole a este nodo una elasticidad precaria para absorber aumentos de temperatura sin sufrir desconexiones totales.